

PLANO DE AÇÕES PÓS-BANCA

Versão revisada e protocolo de execução experimental

Fatigue and Distraction Detection for Heavy Machinery Teleoperation

Pesquisador: Eduardo Lamy Lopes

Programa: Mestrado em Informática — PUCPR

Orientador: Marcelo Eduardo Pellenz

Coorientador: Marco Antonio Simões Teixeira

Horizonte: Seis meses

Objetivo do plano: Converter as recomendações da banca em um protocolo reproduzível, viável e alinhado à hipótese H3, preservando a fusão multimodal como extensão complementar.

1. Direcionamento e escopo

O núcleo da dissertação avaliará como diferentes representações e modelos temporais classificam Alerta, Fadiga e Distração a partir de indicadores faciais, considerando falhas de detecção, duração das janelas e desbalanceamento. A comparação será realizada sobre uma entrada comum, permitindo confrontar regras fixas, classificadores clássicos e arquiteturas temporais.

Prioridade: Concluir um protocolo facial-temporal robusto e explicável. A fusão entre face, corpo e celular não deve bloquear os experimentos centrais.

1.1 Entregas obrigatórias e complementares

Nível	Itens
Obrigatório	Dataset congelado; protocolo de janelas; splits sem vazamento; zero-fill e interpolação; XGBoost, LSTM e TCN; desbalanceamento; ablação; estudos de caso.
Baseline	Regras fixas; zero-fill; distribuição real; classificador clássico sem modelagem temporal.
Complementar	Random Forest, SVM e Transformer; late fusion; SHAP aprofundado em modelos temporais.
Trabalho futuro	Generalização para novos operadores/câmeras; modelos end-to-end sobre vídeo bruto; implantação Edge completa.

2. Dataset e protocolo de anotação

O conjunto atual contém quatro vídeos reais de teleoperação, aproximadamente 122.337 frames e eventos naturais. Os indicadores faciais são EAR, MAR, pitch, yaw e roll. As classes comportamentais permanecem Alerta, Fadiga e Distração.

2.1 Separar classe comportamental de estado operacional

Dimensão	Valores	Uso
Classe comportamental	Alert, Fatigue, Distraction	Target principal dos modelos.
Estado operacional	Valid, FaceMissing, Occlusion, OperatorAbsent	Qualidade/condição da observação; não deve ser confundida com o target.

Operador ausente será tratado primeiro como estado operacional. Uma eventual saída específica de ausência pertence à etapa de fusão e não deve alterar a taxonomia principal antes de sua validação.

2.2 Concordância das anotações

- Selecionar uma amostra estratificada de segmentos de todas as classes, transições, vídeos e condições de iluminação.
- Solicitar revisão independente de aproximadamente 10% a 20% dos segmentos, de acordo com a disponibilidade do segundo anotador.
- Calcular concordância por classe e registrar divergências nas fronteiras temporais dos eventos.
- Usar Cohen's Kappa quando aplicável e documentar o procedimento de consenso.

3. Construção e rotulagem das janelas

Serão avaliadas janelas de 30, 60 e 150 frames. O stride deverá ser explícito em toda execução e a distribuição das classes será recalculada para cada combinação de tamanho, stride e regra de rotulagem.

3.1 Regra primária

1. A classe candidata é a classe majoritária entre os frames válidos da janela.
2. A classe candidata deve atingir a proporção mínima configurada, inicialmente 60%.
3. Se não houver predominância suficiente ou houver empate, a janela recebe a marcação Transition/Mixed.
4. Janelas Transition/Mixed ficam fora do treinamento principal e são mantidas para análise complementar.
5. Janelas com missing rate acima do limite definido no treino são analisadas separadamente; o limite não será escolhido olhando o teste.

3.2 Diagnóstico obrigatório

- Distribuição frame-level por vídeo e classe.
- Distribuição window-level por tamanho de janela, stride e regra de rótulo.
- Missing rate por vídeo, classe, janela e estado operacional.
- Distribuição das durações dos gaps para orientar o limite de interpolação curta.
- Quantidade de janelas mistas e efeito das transições sobre as classes raras.

4. Divisão temporal e generalização

A avaliação externa usará leave-one-video-out, produzindo quatro rodadas. Em cada rodada, um vídeo inteiro será reservado para teste e os três restantes serão usados para treino e validação.

Rodada	Teste	Treino e validação
1	10	90
2	20	80
3	30	70
4	40	60

1	Vídeo 1	Vídeos 2, 3 e 4
2	Vídeo 2	Vídeos 1, 3 e 4
3	Vídeo 3	Vídeos 1, 2 e 4
4	Vídeo 4	Vídeos 1, 2 e 3

4.1 Regras contra vazamento

- A validação interna usará blocos temporais contínuos dentro dos vídeos de treino.
- Janelas sobrepostas não podem atravessar treino, validação e teste.
- Será aplicado purge gap de pelo menos 150 frames entre subconjuntos adjacentes.
- Normalização, imputação, seleção de features, class weights e hiperparâmetros serão estimados somente no treino.
- O fold de teste não será usado para escolher janela, stride, limiar de gap, augmentation ou arquitetura.

Limite da conclusão: Se os quatro vídeos representarem o mesmo operador, o estudo demonstrará generalização entre sessões e condições do domínio estudado, não entre novos operadores.

5. Pré-processamento e representação

5.1 Condições de observação

Condição	Tratamento	Informação adicional
Detecção válida	Usar os cinco indicadores observados.	face_detected = 1
Gap curto	Comparar interpolação linear, forward fill e mediana móvel; selecionar no treino/validação.	was_interpolated = 1
Gap longo	Não interpolar como dado real; usar mediana do treino ou zero no baseline.	missing_duration_so_far
Operador ausente	Registrar como estado operacional separado.	Sinal corporal/ausência

5.2 Representação sequencial

A entrada principal com flags será uma matriz $N \times 8$: [EAR, MAR, Pitch, Yaw, Roll, FaceDetected, WasInterpolated, MissingDurationSoFar]. A duração acumulada do gap é

preferida à duração total, pois não utiliza informação futura e é compatível com inferência em tempo real.

5.3 Features para classificadores clássicos

- Média, mediana, desvio-padrão, mínimo, máximo e amplitude.
- Inclinação temporal e estatísticas dos deltas.
- Proporção de valores acima/abaixo de limiares de referência.
- Missing ratio, quantidade de gaps e maior gap na janela.

LSTM e TCN receberão prioritariamente sinais e flags frame a frame. Features agregadas não serão repetidas em cada frame sem uma comparação específica, para evitar redundância.

6. Estratégia de modelagem

Papel	Modelo	Objetivo
Baseline de domínio	Regras fixas	Comparação com thresholds isolados e sem aprendizado temporal.
Baseline clássico principal	XGBoost	Avaliar features agregadas e oferecer explicabilidade direta.
Temporal recorrente	LSTM	Modelar dependências sequenciais.
Temporal convolucional	TCN	Modelar padrões locais e longos com treinamento eficiente.
Opcional	RF, SVM, Transformer	Comparações complementares sem bloquear o núcleo.

6.1 Execução em duas etapas

6. Usar uma configuração de referência para selecionar pré-processamento, janela e representação sem explorar todas as combinações com todos os modelos.
7. Comparar os modelos principais usando a configuração selecionada e repetir os resultados em todos os folds e seeds definidos.

7. Desbalanceamento e data augmentation

A comparação será controlada e realizada somente depois de estabilizar o pipeline principal.

Cenário	Descrição
A — Original	Treinamento com a distribuição real.

B — Class weights	Maior penalização para erros nas classes raras.
C — Weighted sampling	Maior frequência de janelas raras durante o treino.
D — Augmentation leve	Jitter, pequena variação de escala e masking curto, preservando faixas físicas.

- Augmentation e sampling serão aplicados apenas ao treino.
- Validação e teste manterão a distribuição observada.
- Não combinar weighted sampling e class weights no experimento principal sem hipótese específica.
- Avaliar se o ganho em Macro F1 aumenta falsos alertas por hora.

8. Métricas e análise estatística

Categoria	Métricas
Principal	Macro F1.
Por classe	Precision, recall e F1 para Alert, Fatigue e Distraction.
Balanceamento	Balanced accuracy e matriz de confusão.
Operacional	Falsos alertas por hora/sessão e latência de detecção quando mensurável.
Robustez	Média, desvio-padrão e intervalo de confiança entre folds/seeds.
Eficiência	Tempo de treino, tempo de inferência e tamanho do modelo.

Além da avaliação por janela, eventos completos deverão ser inspecionados para evitar que muitas janelas sobrepostas produzam uma impressão exagerada do tamanho amostral.

9. Explicabilidade

9.1 Importância global

- SHAP e importância interna para XGBoost, quando adequados.
- Permutation importance por indicador e por grupo.
- Relatar estabilidade da importância entre folds, e não apenas uma execução.

9.2 Ablação por grupo

Grupo	Indicadores
-------	-------------

Ocular	EAR
Oral	MAR
Head pose	Pitch, yaw e roll
Missingness	Face detected, interpolated e missing duration
Multimodal opcional	Phone, hands, posture e absence

A ablação principal deverá retreinar o modelo após remover o grupo. Apenas zerar uma feature no teste pode criar entradas fora da distribuição.

9.3 Estudos de caso

- Verdadeiro positivo de fadiga.
- Verdadeiro positivo de distração.
- Falso positivo e falso negativo.
- Caso com alto missing rate para verificar se o modelo aprendeu o comportamento ou a falha do detector.

10. Fusão hierárquica opcional

A late fusion combinará probabilidades do modelo facial-temporal, evidência de celular e sinais corporais. A implementação ocorrerá somente após a conclusão dos experimentos centrais.

- Verificar presença do operador e qualidade da observação.
- Obter probabilidades de alerta, fadiga e distração do módulo facial-temporal.
- Integrar probabilidade de celular e sinais corporais em um meta-classificador simples.
- Avaliar a decisão final e comparar com o melhor modelo facial isolado.

Prevenção de vazamento: O meta-classificador deverá ser treinado com probabilidades out-of-fold dos modelos-base; não com previsões geradas sobre os mesmos exemplos usados para treinar esses modelos.

11. Cronograma revisado

Mês	Foco	Critério de conclusão
1	Dados e protocolo	Dataset/anotações congelados; regra de janela; diagnóstico; folds e registro de decisões.
2	Pré-processamento	Zero-fill, interpolação, flags e features implementados e testados sem vazamento.

3	Modelos centrais	Regras, XGBoost, LSTM e TCN executados; janela e configuração principal selecionadas.
4	Desbalanceamento	Original, class weights, sampling e augmentation comparados com métricas operacionais.
5	Explicabilidade	Ablação, importance e estudos de caso concluídos; fusão apenas se o núcleo estiver fechado.
6	Síntese e defesa	Testes finais, estatística, limitações, texto revisado e materiais da defesa.

11.1 Escrita contínua

A escrita não será concentrada no sexto mês. Ao final de cada mês, deverão ser atualizados metodologia, registro de decisões, tabelas de resultados e limitações. O mês 6 ficará reservado à integração e revisão.

12. Critérios de decisão e riscos

Risco	Mitigação
Poucos vídeos	Leave-one-video-out, intervalos de confiança e conclusões restritas ao domínio estudado.
Fadiga rara	Macro F1, recall por classe, pesos/sampling/augmentation e análise de falsos alertas.
Falha do Face Mesh	Flags, análise de missingness, interpolação curta e estudo de caso específico.
Escopo excessivo	XGBoost, LSTM e TCN como núcleo; Transformer e fusão condicionados ao tempo.
Vazamento temporal	Splits por vídeo/blocos, purge gap, fit de transformações apenas no treino e testes automatizados.
Viés de anotação	Segundo anotador em amostra estratificada e análise de concordância.

13. Justificativa da abordagem baseada em indicadores

Embora abordagens end-to-end sobre vídeo bruto sejam possíveis, o conjunto disponível é limitado para o treinamento confiável de modelos espaço-temporais de alta capacidade. Os indicadores faciais reduzem a dimensionalidade, incorporam conhecimento do domínio, diminuem o custo computacional e tornam as decisões mais interpretáveis. Essa representação comum também permite comparar regras fixas, classificadores clássicos e modelos temporais de forma controlada.

A limitação é a dependência da qualidade da detecção facial, observada nas diferentes taxas de detecção entre os vídeos. Por isso, missingness e estados operacionais fazem parte explícita do protocolo, em vez de serem tratados apenas como ruído.

Apêndice A — Estrutura recomendada do repositório Git

O repositório deve ser organizado por etapas reproduzíveis, e não por notebooks ou modelos isolados. Dados sensíveis e artefatos pesados permanecem fora do Git.

```
configs/
  data/ splits/ preprocessing/ experiment/
data/
  raw/ interim/ processed/ manifests/
docs/
  methodology/ decisions/ data_dictionary.md
notebooks/
outputs/
  metrics/ figures/ models/ predictions/ logs/
reports/
scripts/
src/
  data/ preprocessing/ features/ models/
  training/ evaluation/ explainability/ fusion/ utils/
tests/
```

A.1 Regras de versionamento

- Não versionar vídeos, frames, modelos treinados, dados pessoais, caminhos internos ou arquivos da empresa.
- Versionar configurações, código, manifestos anonimizados, testes, documentação metodológica e métricas consolidadas quando permitido.
- Registrar hash do commit, configuração, fold, seed, versão do dataset e métricas em cada execução.
- Manter notebooks apenas para exploração; lógica reutilizável deve migrar para src/.
- Criar testes para rotulagem das janelas, ausência de sobreposição temporal, interpolação e cálculo das métricas.