

PLANO DE AÇÕES PÓS-BANCA

Versão integrada, protocolo de execução experimental e guia de implementação com GPU

FATIGUE AND DISTRACTION DETECTION FOR HEAVY MACHINERY TELEOPERATION

Campo	Informação
Pesquisador	Eduardo Lamy Lopes
Programa	Mestrado em Informática — PUCPR
Orientador	Marcelo Eduardo Pellenz
Coorientador	Marco Antonio Simões Teixeira
Horizonte	Seis meses
Implementação	Projeto organizado dentro de fase_2

Objetivo: converter os compromissos da qualificação e as recomendações da banca em um protocolo científico reproduzível e em um plano de implementação executável, com uso controlado de GPU, prevenção de vazamento temporal, rastreabilidade completa e critérios objetivos de conclusão.

Sumário executivo

Este documento substitui o plano pós-banca atualizado. Ele preserva a hipótese H3 e os compromissos apresentados na qualificação, incorpora as recomendações da banca e acrescenta as regras de engenharia necessárias para que a implementação seja reproduzível. A prioridade continua sendo o módulo facial-temporal; a fusão com corpo e celular permanece complementar e não deve bloquear os experimentos centrais.

Resultado científico esperado: determinar se fronteiras de decisão aprendidas sobre séries temporais multivariadas superam regras com limiares fixos e classificadores que não preservam a ordem temporal, no contexto real de teleoperação de mineração.

Estrutura do documento

Parte	Conteúdo
I — Protocolo científico	Escopo, dados, janelas, validação, modelos, métricas, explicabilidade e fusão.
II — Engenharia experimental	GPU, early stopping, checkpoints, versionamento, gerações, testes e rastreabilidade.
III — Execução	Cronograma, critérios de aceite, riscos e definição de conclusão.
Apêndice A	Matriz mínima de experimentos e convenção de identificação.
Apêndice B	Prompt completo para o Cortex implementar e organizar o projeto em fase_2.

Princípios obrigatórios

- Uma única hipótese principal: H3, com comparação justa sobre entradas e divisões equivalentes.
- Nenhum ajuste pode usar informações do vídeo externo reservado para teste.
- Cada ganho deve ser associado a uma mudança experimental identificável.
- Resultados devem ser repetidos por fold e seed, com configuração e código rastreáveis.
- Dados sensíveis, vídeos, frames e modelos treinados não devem ser versionados no Git.
- O Cortex não deve fabricar dados, resultados, anotações, métricas ou caminhos inexistentes.

1. Alinhamento com a qualificação

1.1 Objetivo geral preservado

Investigar e avaliar arquiteturas temporais para detectar fadiga e distração em operadores de máquinas pesadas em teleoperação, aprendendo a partir de múltiplos indicadores faciais e de sua progressão temporal, com dados específicos do domínio de mineração fornecidos pela empresa parceira.

1.2 Hipótese principal

H3: arquiteturas temporais capazes de processar janelas de múltiplos indicadores faciais superam abordagens baseadas em regras e classificadores sem modelagem temporal na detecção de fadiga e distração.

1.3 Compromissos experimentais

Elemento	Compromisso
Classes	Alert, Fatigue e Distraction.
Indicadores	EAR, MAR, Pitch, Yaw e Roll.
Baselines	Regras fixas; SVM; Random Forest; XGBoost.
Temporais	LSTM; TCN; Transformer.
Janelas	30, 60 e 150 frames, com stride explícito.
Principal métrica	Macro F1.
Validação externa	Leave-one-video-out com quatro rodadas.
Contribuição	Fronteiras aprendidas, combinação de indicadores e contexto temporal.

1.4 Limites da conclusão

- A etapa de extração facial com MediaPipe Face Mesh e OpenCV é tratada como componente fixo.
- O estudo não treina modelos espaço-temporais diretamente sobre vídeo bruto.
- Generalização entre operadores, câmeras e minas não pode ser afirmada com os dados atuais.
- Se os quatro vídeos forem do mesmo operador, a conclusão será restrita à generalização entre sessões e condições observadas.
- Exportação ONNX, implantação Edge completa e novos sensores permanecem trabalho futuro.

2. Direcionamento e prioridades

Nível	Entregas
Obrigatório	Dataset congelado; janelas; splits sem vazamento; zero-fill; interpolação; flags; regras; SVM; RF; XGBoost; LSTM; TCN; Transformer; janelas 30/60/150; desbalanceamento; ablação; estudos de caso.
Núcleo aprofundado	XGBoost, LSTM e TCN, com maior orçamento de busca e repetição.
Comparação controlada	SVM, Random Forest e Transformer com espaço de busca menor, mas resultados documentados.
Complementar	Late fusion; SHAP aprofundado em temporais; calibração avançada.
Futuro	Novos operadores; vídeo bruto; implantação Edge; telemetria e sensores fisiológicos.

A fusão face-corpo-celular somente começa quando o protocolo facial-temporal estiver fechado, executado e analisado. Ela não pode consumir o tempo necessário para responder à H3.

3. Dataset, taxonomia e qualidade das anotações

3.1 Conjunto de dados

O conjunto atual contém quatro vídeos reais de teleoperação, aproximadamente 119 minutos e 122.337 frames. Os eventos são naturais, não simulados. Para cada frame, o pipeline deve manter identificação de vídeo, índice do frame, timestamp quando disponível, rótulo comportamental, estado operacional e os cinco indicadores faciais.

3.2 Separação entre target e condição de observação

Dimensão	Valores	Uso
Classe comportamental	Alert, Fatigue, Distraction	Target principal.
Estado operacional	Valid, FaceMissing, Occlusion, OperatorAbsent	Condição da observação; não confundir com target.
Transition/Mixed	Janela sem predominância suficiente	Fora do treino principal; análise complementar.

3.3 Congelamento e manifesto

- Criar uma versão identificável do dataset e nunca sobrescrevê-la silenciosamente.
- Registrar hash ou assinatura dos arquivos derivados e das anotações, sem expor dados sensíveis.
- Manter um dicionário de dados com unidades, faixas esperadas, valores ausentes e semântica das flags.
- Executar verificações de duplicidade, ordem temporal, timestamps, rótulos inválidos e descontinuidade de frames.

3.4 Concordeância

- Selecionar amostra estratificada de 10% a 20% dos segmentos, conforme disponibilidade do segundo anotador.
- Cobrir classes, transições, vídeos, iluminação, oclusão e ausência.
- Calcular Cohen's Kappa quando aplicável e registrar divergências nas fronteiras dos eventos.
- Documentar o procedimento de consenso sem alterar o teste após observar resultados dos modelos.

4. Construção e rotulagem das janelas

4.1 Tamanhos e stride

Serão avaliadas janelas de 30, 60 e 150 frames. Considerando aproximadamente 17 FPS, elas correspondem a cerca de 1,8 s, 3,5 s e 8,8 s. O stride será parâmetro obrigatório e aparecerá no identificador de cada execução.

4.2 Regra principal de rótulo

- A classe candidata será a classe majoritária entre os frames comportamentais válidos.
- A classe deverá alcançar proporção mínima configurada, inicialmente 60%.
- Empate ou predominância insuficiente produzirá Transition/Mixed.
- Transition/Mixed ficará fora do treinamento principal e será preservada para análise de fronteiras.
- O limite de missing rate será estimado exclusivamente com treino e validação.

4.3 Diagnósticos obrigatórios

- Distribuição frame-level por vídeo e classe.
- Distribuição window-level por janela, stride e regra de rótulo.
- Missing rate por vídeo, classe, janela e estado operacional.
- Distribuição das durações dos gaps para orientar interpolação curta.
- Quantidade de janelas mistas, cobertura temporal e efeito sobre classes raras.
- Número de eventos independentes por classe, além do número de janelas sobrepostas.

5. Divisão temporal e prevenção de vazamento

5.1 Avaliação externa

Fold	Teste externo	Treino e validação
1	Vídeo 1	Vídeos 2, 3 e 4
2	Vídeo 2	Vídeos 1, 3 e 4
3	Vídeo 3	Vídeos 1, 2 e 4
4	Vídeo 4	Vídeos 1, 2 e 3

5.2 Validação interna

Dentro dos três vídeos disponíveis no fold externo, a seleção de hiperparâmetros e o early stopping usarão blocos temporais contínuos. O vídeo externo ficará bloqueado até a configuração daquele fold estar definida.

5.3 Regras invariáveis

- Janelas sobrepostas não atravessam treino, validação ou teste.
- Aplicar purge gap de pelo menos 150 frames entre subconjuntos adjacentes.
- Imputação, normalização, seleção de features, pesos e augmentation são ajustados apenas no treino.
- Validação e teste mantêm a distribuição observada; sampling e augmentation não são aplicados neles.
- O fold externo não escolhe janela, stride, gap, arquitetura ou política de balanceamento.
- Criar testes automatizados que falhem se houver sobreposição de vídeo, frame ou intervalo temporal.

6. Pré-processamento e representações

6.1 Condições de observação

Condição	Tratamento	Informação adicional
Válida	Usar os cinco indicadores observados.	face_detected=1
Gap curto	Comparar interpolação linear, forward fill e mediana móvel.	was_interpolated=1
Gap longo	Não tratar como medição real; zero no baseline ou mediana do treino.	missing_duration_so_far
Ausente	Registrar estado operacional separado.	sinal de ausência

6.2 Representações reconciliadas

Código	Representação	Finalidade
R0	N×5 com zero-fill	Reproduzir a entrada apresentada na qualificação.
R1	N×5 após interpolação curta	Isolar o efeito da imputação.
R2	N×8: cinco sinais + três flags	Medir o valor explícito da missingness.
R3	Features agregadas por janela	Entrada interpretável para XGBoost como extensão pós-banca.

As três flags de R2 são FaceDetected, WasInterpolated e MissingDurationSoFar. A duração acumulada até o frame atual é preferida à duração total do gap, pois não utiliza o futuro e é compatível com inferência online.

6.3 Features agregadas

- Média, mediana, desvio-padrão, mínimo, máximo e amplitude.
- Inclinação temporal, deltas e estatísticas dos deltas.
- Proporção acima ou abaixo dos limiares de referência, somente como feature e não como regra final.
- Missing ratio, número de gaps, maior gap e duração acumulada.
- Features agregadas não devem ser repetidas em cada frame da LSTM ou TCN sem experimento específico.

7. Estratégia de modelagem

Papel	Modelo	Entrada mínima	Pergunta
B1	Regras fixas	EAR, MAR, Pitch	Quanto os thresholds conseguem resolver?
B2a	SVM, RF, XGBoost	Janela N×5 achatada	Fronteiras aprendidas ajudam sem sequência explícita?
B2b	XGBoost	Features agregadas R3	Engenharia de features melhora o clássico?
P1	LSTM	R0 e representação selecionada	Dependências recorrentes ajudam?
P2	TCN	R0 e representação selecionada	Padrões temporais convolucionais ajudam?
P3	Transformer	R0 e representação selecionada	Atenção é viável com poucos dados?

7.1 Fronteiras aprendidas

Nos modelos aprendidos, nenhum valor fixo de EAR, MAR ou Head Pose determina diretamente a classe. O classificador aprende combinações e fronteiras a partir do treino. A decisão oficial será argmax das probabilidades, salvo se algum limiar probabilístico ou calibração for pré-definido e ajustado apenas na validação.

7.2 Justiça da comparação

- Mesmos folds, seeds, janelas e targets para modelos comparáveis.
- Não usar informações adicionais em apenas um modelo sem nomear a comparação como extensão.
- Registrar número de parâmetros, tempo de treino, inferência e tamanho do artefato.
- Não concluir superioridade temporal apenas comparando uma TCN ajustada com um baseline sem ajuste razoável.

8. Gerações experimentais

As gerações devem ser especificadas antes da avaliação externa. Cada uma introduz uma mudança rastreável. Novas gerações criadas após observar o teste serão marcadas como exploratórias.

Geração	Mudança	Entregável e critério
G0 — Smoke	Pipeline mínimo e GPU	Um fold, uma janela, 2-3 épocas; forward/backward, checkpoint e resume funcionando.
G1 — Qualificação	R0, regras e clássicos achatados	Reproduzir o cenário defendido e gerar métricas válidas.
G2 — Temporal	LSTM, TCN e Transformer sobre R0	Comparar sequência contra B1/B2 nos três tamanhos.
G3 — Missingness	R1/R2 e interpolação	Isolar ganho de imputação e flags.

Geração	Mudança	Entregável e critério
G4 — Imbalance	Pesos, sampling e augmentation	Medir Macro F1, recall raro e falsos alertas.
G5 — Final	Melhor configuração + ablação	Todos os folds/seeds, estatística, explicabilidade e estudos de caso.
G6 — Fusão	Face + corpo + celular	Opcional; somente após fechamento de G5.

9. Seleção de configurações e hiperparâmetros

9.1 Evitar busca exaustiva

Não será usado um grid search cartesiano sobre todos os modelos, janelas, preprocessamentos, folds e seeds. O custo e o risco de selecionar ruído seriam desproporcionais ao tamanho do conjunto.

9.2 Estratégia em duas etapas

- Triagem: uma seed, espaço pequeno e orçamento limitado, usando apenas treino/validação interna.
- Confirmação: melhores configurações executadas nos quatro folds e em pelo menos três seeds.
- O espaço de busca deve ser fixado em YAML e salvo junto do resultado.
- XGBoost, LSTM e TCN recebem maior orçamento; SVM, RF e Transformer recebem busca menor, mas justa.

9.3 Critério de escolha

- Principal: maior Macro F1 de validação.
- Desempate: recall de Fatigue, falsos alertas por hora e menor complexidade.
- Acurácia global não deve selecionar o modelo.
- O teste externo é executado após a configuração do fold estar definida.

10. Desbalanceamento e augmentation

Cenário	Tratamento
A — Original	Distribuição real, sem balanceamento.
B — Class weights	Maior penalização para erros nas classes raras.
C — Weighted sampling	Maior frequência de janelas raras no treino.
D — Augmentation leve	Jitter, pequena escala e masking curto, preservando faixas físicas.

- Aplicar sampling e augmentation apenas no treino.
- Não combinar class weights e weighted sampling no experimento principal sem hipótese específica.
- Augmentation deve preservar coerência temporal, faixas fisiológicas e correlação entre indicadores.
- Comparar ganho de Macro F1 com recall de Fatigue e falsos alertas por hora.
- Salvar uma amostra auditável das transformações, sem expor vídeo ou dados identificáveis.

11. Treinamento com GPU, early stopping e checkpoints

11.1 Responsabilidade da GPU

A GPU será usada prioritariamente para LSTM, TCN e Transformer. Geração de janelas, diagnósticos e baselines clássicos poderão permanecer na CPU. O pipeline deve funcionar em CPU para testes e selecionar CUDA automaticamente quando disponível.

11.2 Configuração inicial

```
training:
device: auto
max_epochs: 150
mixed_precision: true
early_stopping:
monitor: val_macro_f1
mode: max
patience: 15
min_delta: 0.002
checkpoint:
save_best: true
save_last: true
metric: val_macro_f1
```

11.3 Checkpoints obrigatórios

- best_macro_f1.pt: único checkpoint oficial usado para avaliação do fold.
- last.pt: retomada segura após interrupção.
- Salvar modelo, otimizador, scheduler, scaler, época, melhor métrica, fold, seed e configuração.
- Registrar hash do commit, versão do dataset, versões das bibliotecas, GPU e CUDA.
- Quando possível, salvar estados aleatórios para retomada fiel.

11.4 Execução segura

- Executar smoke test de 2-3 épocas antes de treinamentos longos.
- Usar mixed precision quando suportado e validar ausência de NaN/Inf.
- Batch size configurável; usar gradient accumulation apenas quando necessário.
- Registrar uso de memória e evitar processos longos sem logs ou checkpoints.
- Retomar execução existente em vez de sobrescrever resultados válidos.

12. Métricas e análise estatística

Categoria	Métricas
Principal	Macro F1.
Por classe	Precision, recall e F1 para Alert, Fatigue e Distraction.
Balanceamento	Balanced accuracy e matriz de confusão.
Probabilística	AUC-ROC one-vs-rest quando válida; curvas e calibração como complementares.
Operacional	Falsos alertas por hora/sessão e latência de detecção quando mensurável.
Robustez	Média, desvio-padrão e intervalo de confiança entre folds/seeds.
Eficiência	Tempo de treino, inferência, parâmetros, tamanho e pico de memória.

12.1 Unidade de análise

A avaliação por janela será acompanhada de análise por evento e sessão. Janelas sobrepostas não representam observações independentes. O número de eventos completos e a cobertura temporal deverão aparecer junto do número de janelas.

12.2 Significância

- Manter McNemar como comparação planejada, mas não aplicá-lo ingenuamente a milhares de janelas sobrepostas.
- Quando usado, aplicar sobre predições pareadas compatíveis e relatar a unidade analisada.
- Complementar com bootstrap em blocos temporais ou por eventos, reconhecendo a limitação de apenas quatro sessões.

- Priorizar magnitude do efeito, consistência entre folds e intervalos de confiança em vez de apenas p-valor.

13. Explicabilidade e ablação

13.1 Importância global

- SHAP e importância interna para XGBoost.
- Permutation importance por indicador e grupo.
- Estabilidade da importância entre folds e seeds.

13.2 Grupos de ablação

Grupo	Variáveis
Ocular	EAR
Oral	MAR
Head pose	Pitch, Yaw e Roll
Missingness	FaceDetected, WasInterpolated, MissingDurationSoFar
Multimodal opcional	Phone, hands, posture e absence

A ablação principal deve retreinar o modelo após remover o grupo. Zerar uma feature apenas no teste pode criar entradas fora da distribuição e não substitui a ablação.

13.3 Estudos de caso

- Verdadeiro positivo de Fatigue.
- Verdadeiro positivo de Distraction.
- Falso positivo e falso negativo.
- Caso com alto missing rate para verificar se o modelo aprendeu comportamento ou falha do detector.

14. Fusão hierárquica opcional

A late fusion combinará probabilidades do módulo facial-temporal, evidência de celular e sinais corporais. A saída principal permanece Alert, Fatigue e Distraction; OperatorAbsent será inicialmente estado operacional separado.

- Gerar probabilidades out-of-fold dos modelos-base.
- Treinar meta-classificador somente com previsões out-of-fold, nunca com previsões dos mesmos exemplos usados para treinar a base.
- Comparar a fusão com o melhor modelo facial isolado.
- Registrar se o ganho ocorre em Fatigue, Distraction, ausência ou apenas em acurácia global.

15. Organização do projeto fase_2

```
fase_2/
README.md
pyproject.toml
configs/
data/ preprocessing/ model/ experiment/ generation/
data/
raw/ interim/ processed/ manifests/
docs/
methodology/ decisions/ data_dictionary.md
notebooks/
outputs/
metrics/ figures/ models/ predictions/ logs/ runs/
reports/
scripts/
src/
data/ preprocessing/ features/ models/
training/ evaluation/ explainability/ fusion/ utils/
tests/
```

15.1 Regras de versionamento

- Não versionar vídeos, frames, checkpoints, modelos treinados, dados pessoais ou caminhos internos da empresa.
- Versionar código, configurações, manifestos anonimizados, testes, documentação e métricas consolidadas quando permitido.
- Notebooks servem para exploração; lógica reutilizável deve migrar para src/.
- Não modificar fase_1; ela é fonte histórica e de dados já produzidos.
- Antes de editar, verificar arquivos existentes e preservar mudanças do usuário.

15.2 Identificador de execução

```
{generation}_{model}_{representation}_w{window}_s{stride}_fold{fold}_seed{seed}
Exemplo: G3_tcn_R2_w60_s15_fold2_seed42
```

15.3 Registro mínimo

- Configuração resolvida, comando, início/fim, status e motivo de falha.
- Commit, dataset, fold, seed, ambiente e hardware.
- Histórico por época, checkpoint escolhido, métricas e predições.
- Resumo consolidado que possa ser regenerado sem abrir notebooks.

16. Testes e quality gates

Gate	Condição para avançar
Q0 — Dados	Schema, ordem temporal, rótulos e manifestos validados.
Q1 — Janelas	Distribuições geradas e testes de rotulagem aprovados.
Q2 — Splits	Zero interseção e purge gap confirmado automaticamente.
Q3 — Preprocessamento	Fit apenas no treino; gaps e flags testados.
Q4 — Treinamento	Smoke test, GPU/CPU, checkpoint e resume aprovados.
Q5 — Avaliação	Métricas unitárias conferidas e predições rastreáveis.
Q6 — Geração	Todos os experimentos planejados completos ou falhas justificadas.
Q7 — Final	Folds/seeds, figuras, tabelas, limitações e decisão sobre H3.

17. Cronograma de seis meses

Mês	Foco	Critério de conclusão
1	Dados e protocolo	Dataset congelado; dicionário; janelas; diagnóstico; folds; decisões e testes contra vazamento.
2	Pré-processamento	R0-R3 implementadas; zero-fill; interpolação; flags; features e testes.
3	Modelos e GPU	G0-G2; regras; SVM; RF; XGBoost; LSTM; TCN; Transformer; checkpoints e janelas.
4	Desbalanceamento	G3-G4; original, pesos, sampling e augmentation comparados.
5	Explicabilidade	G5; ablação, importance, estudos de caso; fusão somente se o núcleo estiver fechado.
6	Síntese e defesa	Reexecuções finais; estatística; tabelas; limitações; texto e materiais da defesa.

A escrita é contínua: ao fim de cada mês devem ser atualizados metodologia, decisões, resultados, figuras e limitações. O sexto mês é reservado à integração e revisão.

18. Riscos e mitigação

Risco	Mitigação
Poucos vídeos	Leave-one-video-out; resultados por sessão; conclusão restrita ao domínio.
Fatigue rara	Macro F1; recall por classe; pesos/sampling/augmentation; falsos alertas.
Falha do Face Mesh	R0-R2; flags; interpolação curta; análise de missingness.
Vazamento temporal	Splits por vídeo/bloco; purge gap; fit no treino; testes automatizados.
Escopo excessivo	Núcleo XGBoost/LSTM/TCN; comparação enxuta dos demais; fusão condicionada.
Busca excessiva	Espaço limitado; triagem; orçamento; geração pré-registrada.
GPU interrompida	last.pt; resume; logs por época; smoke test.
Resultados ruins	Auditar rótulos, distribuição, missingness e leakage; avaliar binário apenas como contingência documentada.
Viés de anotação	Segundo anotador em amostra estratificada e concordância.

19. Definição de conclusão

O núcleo do projeto estará concluído quando:

- O dataset e os folds estiverem congelados e reproduzíveis.
- As três janelas e os seis modelos prometidos estiverem avaliados em protocolo comparável.
- R0 e a representação pós-banca selecionada estiverem comparadas.
- As estratégias de desbalanceamento estiverem documentadas com métricas operacionais.
- As configurações finais tiverem quatro folds e múltiplas seeds.
- As conclusões sobre H3 forem sustentadas por resultados por classe, eventos e sessões.
- O melhor modelo tiver checkpoint, configuração, predições, métricas, ablação e estudos de caso rastreáveis.
- Falhas, limitações e decisões negativas também estiverem documentadas.

Apêndice A — Matriz mínima de experimentos

Bloco	Variação obrigatória	Observação
Janelas	30, 60, 150	Stride explícito; mesma regra de rotulagem.
Regras	B1	Thresholds fixos da literatura como referência.
Clássicos defendidos	SVM, RF, XGBoost em R0 achatada	Preserva o desenho da qualificação.
Clássico pós-banca	XGBoost em R3	Features agregadas e interpretáveis.
Temporais	LSTM, TCN, Transformer em R0	Comparação central de paradigmas.
Missingness	R0, R1, R2	Pode ser aprofundada no melhor clássico e nos temporais centrais.
Balanceamento	A, B, C, D	Executar após estabilizar pipeline; priorizar modelos centrais.
Final	4 folds $\times$ ≥ 3 seeds	Somente configurações selecionadas na validação.
Ablação	Ocular, oral, pose, missingness	Retreinar após remover o grupo.

Tabela mestre de resultados

O agregador deverá produzir ao menos as colunas: run_id, generation, model, representation, window, stride, fold, seed, balancing, preprocessing, best_epoch, Macro F1, métricas por classe, balanced accuracy, falsos alertas, latência, tempo de treino, parâmetros, tamanho, commit, dataset_version e status.

Apêndice B — Prompt completo para o Cortex

Copiar o texto a seguir integralmente para o Cortex no VS Code, com o workspace aberto no diretório que contém fase_1 e fase_2. O agente deve trabalhar somente em fase_2 e executar a implementação por checkpoints verificáveis.

Papel e objetivo

Você é o agente de engenharia responsável por organizar e implementar, dentro da pasta fase_2, um projeto científico completo e reproduzível de machine learning para detecção de fadiga e distração em teleoperação de máquinas pesadas. O projeto faz parte de uma dissertação de mestrado já qualificada. Preserve o escopo científico e trate o código como infraestrutura de pesquisa auditável, não como um protótipo descartável.

O objetivo científico é avaliar se modelos que aprendem fronteiras de decisão sobre janelas temporais de indicadores faciais superam: (1) regras com thresholds fixos e (2) classificadores clássicos que não modelam explicitamente a ordem temporal. As classes principais são Alert, Fatigue e Distraction. Os indicadores por frame são EAR, MAR, Pitch, Yaw e Roll. Os tamanhos de janela obrigatórios são 30, 60 e 150 frames. Os modelos prometidos são regras fixas, SVM, Random Forest, XGBoost, LSTM, TCN e Transformer. A métrica principal é Macro F1.

Limites de atuação

Trabalhe exclusivamente dentro de fase_2. Não edite, mova, renomeie ou exclua arquivos de fase_1. Fase_1 pode ser lida apenas como referência ou fonte de artefatos existentes. Não copie vídeos desnecessariamente. Não versione vídeos, frames, checkpoints, modelos treinados, dados pessoais, segredos, caminhos internos da empresa ou grandes outputs.

Antes de alterar qualquer arquivo, inspecione o workspace, leia AGENTS.md e documentação existente, execute git status e identifique mudanças do usuário. Preserve tudo o que não pertence à tarefa. Não use comandos destrutivos. Não fabrique datasets, rótulos, métricas ou resultados. Quando uma informação essencial estiver ausente, implemente a interface e a validação correspondente, documente o bloqueio e solicite o dado exato necessário.

Não inicie treinamentos longos antes de concluir validações de dados, splits, smoke tests, checkpoints e estimativa de custo. Não use o conjunto de teste para escolher hiperparâmetros, préprocessamento, janela, stride, augmentation ou arquitetura.

Fase inicial de inspeção

1. Inspecione a estrutura atual de fase_2 e localize dados, anotações, CSVs, scripts, dependências e documentação.
2. Verifique formatos, colunas, unidades, FPS, convenções de rótulo e como os cinco indicadores são representados quando o rosto não é detectado.
3. Identifique se existem quatro vídeos e como as linhas se relacionam com video_id, frame_idx e timestamp.
4. Verifique GPU com nvidia-smi e, no ambiente Python, torch.cuda.is_available(), nome do dispositivo, versão do PyTorch e CUDA. Não falhe definitivamente se não houver GPU: mantenha device=auto e suporte CPU para testes.
5. Produza docs/current_state.md com inventário factual, lacunas, riscos e decisões já existentes.
6. Produza um plano de execução curto em docs/implementation_plan.md e avance em etapas, atualizando o status após cada quality gate.

Se o workspace já tiver uma estrutura funcional, adapte-a em vez de recriar tudo. Prefira mudanças pequenas e verificáveis.

Estrutura alvo

Organize fase_2 com README.md, pyproject.toml ou dependências equivalentes, configs, data, docs, notebooks, outputs, reports, scripts, src e tests. Dentro de configs, separe data, preprocessing, model, experiment e generation. Dentro de src, separe data, preprocessing, features, models, training, evaluation, explainability, fusion e utils.

Mantenha notebooks apenas para exploração. Toda lógica reutilizável deve estar em src. Scripts devem ser wrappers finos que chamam módulos testáveis. Use caminhos relativos ao projeto ou resolvidos por configuração; não codifique caminhos absolutos da máquina do pesquisador.

Configure .gitignore para dados sensíveis e pesados, incluindo vídeos, frames extraídos, outputs de runs, checkpoints, logs volumosos, caches, ambientes virtuais e credenciais. Não ignore configurações, testes, documentação, métricas consolidadas permitidas e manifestos anonimizados.

Configuração e reprodutibilidade

Implemente configuração em YAML para dataset, split, janelas, preprocessing, modelo, treino, avaliação e geração experimental. Cada execução deve salvar a configuração totalmente resolvida.

Use seeds explícitas para Python, NumPy e PyTorch. Registre limitações de determinismo quando CUDA usar operações não determinísticas. Capture versões de Python, bibliotecas, PyTorch, CUDA e GPU. Registre hash do commit, versão do dataset, fold, seed, comando, horários, status e motivo de falha.

Adote run_id no formato

{generation}_{model}_{representation}_w{window}_s{stride}_fold{fold}_seed{seed}. Nunca sobrescreva silenciosamente uma execução concluída. Se a configuração for idêntica e houver checkpoint last.pt, permita resume. Se houver conflito, crie novo run_id ou aborte com mensagem clara.

Dados e schema

Defina e valide um schema canônico por frame contendo ao menos video_id, frame_idx, timestamp quando disponível, EAR, MAR, Pitch, Yaw, Roll, behavioral_label e operational_state. Preserve as classes Alert, Fatigue e Distraction como target. Trate Valid, FaceMissing, Occlusion e OperatorAbsent como estado operacional, não como classe comportamental, salvo experimento futuro explicitamente nomeado.

Crie data_dictionary.md com significado, tipo, unidade, faixa plausível e política de missing de cada campo. Implemente validações para duplicatas, ordenação, frames ausentes, labels desconhecidos, NaN/Inf, indicadores fora de faixas plausíveis e inconsistências temporais. Não corrija valores silenciosamente: gere relatório e aplique apenas transformações configuradas.

Crie manifesto versionável e anonimizado. Se os dados forem sensíveis, registre apenas identificadores abstratos, contagens, hashes permitidos e metadados necessários à reprodução.

Janelas e rótulos

Implemente geração de janelas para 30, 60 e 150 frames, com stride obrigatório e configurável. A classe candidata deve ser a maioria entre os frames comportamentais válidos e alcançar proporção mínima inicial de 60%. Empate ou predominância insuficiente deve resultar em Transition/Mixed. Essas janelas ficam fora do treino principal, mas permanecem em relatórios e análises complementares.

Calcule e salve distribuição frame-level e window-level por vídeo, classe, tamanho, stride e regra. Calcule missing rate por vídeo, classe, janela e estado operacional; distribuição das durações dos gaps; número de janelas mistas; cobertura temporal; e número de eventos independentes por classe.

Crie testes unitários com sequências artificiais pequenas para maioria, empate, proporção mínima, transição, missing e bordas do vídeo. A geração de janelas deve ser determinística.

Splits sem vazamento

Implemente leave-one-video-out externo com quatro folds. Em cada fold, reserve um vídeo completo para teste e use os três restantes em treino e validação. A validação interna deve usar blocos temporais contínuos. Aplique purge gap mínimo de 150 frames entre subconjuntos adjacentes. Nenhuma janela pode cruzar limites de treino, validação ou teste.

Normalizadores, imputadores, seleção de features, class weights, sampling e qualquer estatística devem ser ajustados somente no treino. O vídeo externo nunca escolhe configuração.

Implemente testes automatizados que falhem se houver: mesmo video_id indevidamente compartilhado no teste externo; interseção de índices ou intervalos; janela atravessando split; purge gap insuficiente;

ou fit de transformação fora do treino. Gere manifesto de cada fold com intervalos e contagens.

Preprocessamento

Implemente representações nomeadas:

R0: $N \times 5$ com zero-fill, reproduzindo a qualificação.

R1: $N \times 5$ com tratamento configurável de gaps curtos.

R2: $N \times 8$ com EAR, MAR, Pitch, Yaw, Roll, FaceDetected, WasInterpolated e MissingDurationSoFar.

R3: features agregadas por janela para classificadores clássicos.

Compare interpolação linear, forward fill e mediana móvel apenas para gaps curtos. O limite de gap deve ser configuração selecionada no treino/validação. Gaps longos não devem ser transformados em medições fisiológicas reais. Use zero no baseline ou mediana calculada no treino e sempre preserve flags.

MissingDurationSoFar deve usar apenas o passado até o frame corrente; não use duração total do gap, pois isso vazaria informação futura em inferência online.

Para R3, implemente média, mediana, desvio-padrão, mínimo, máximo, amplitude, inclinação, deltas, estatísticas dos deltas, proporções relativas a thresholds de referência, missing ratio, número de gaps e maior gap. Faça fit de normalização apenas no treino.

Modelos

Implemente uma interface comum fit/predict_proba/save/load ou equivalente para:

B1: regras fixas usando EAR, MAR e Pitch conforme o baseline documentado.

B2a: SVM, Random Forest e XGBoost sobre R0 achatada.

B2b: XGBoost sobre R3.

P1: LSTM.

P2: TCN com convoluções temporais dilatadas.

P3: Transformer pequeno, adequado a cinco ou oito features e dataset limitado.

Todos devem produzir classes na mesma ordem e, quando possível, probabilidades. Não implemente modelos excessivamente grandes. Registre parâmetros treináveis, tamanho serializado, tempo de treino e tempo de inferência.

Nos modelos aprendidos, não aplique thresholds fixos de EAR/MAR/Pose como lógica final. Esses valores podem existir apenas no baseline B1 ou como features de referência em R3. A classificação aprendida usa argmax das probabilidades, salvo calibração ou threshold probabilístico ajustado exclusivamente na validação e documentado.

Treinamento com GPU

Crie um training engine PyTorch compartilhado por LSTM, TCN e Transformer. Use device=auto, suporte CPU e CUDA, mixed precision com autocast e GradScaler quando compatível, DataLoader com pin_memory quando CUDA estiver ativa e num_workers configurável. Mantenha batch size em configuração e ofereça gradient accumulation somente se necessário.

Implemente early stopping monitorando val_macro_f1, mode=max, max_epochs inicial 150, patience inicial 15 e min_delta inicial 0.002. Esses valores devem ser configuráveis. Integre scheduler sem criar uma busca exagerada.

Salve best_macro_f1.pt como checkpoint oficial e last.pt para retomada. O checkpoint deve conter modelo, otimizador, scheduler, scaler, época, melhor métrica, configuração, fold, seed, classes e metadados necessários. Valide save/load e resume com teste automatizado ou smoke test.

Antes de qualquer treinamento longo, execute 2–3 épocas em pequena amostra e confirme forward, backward, ausência de NaN/Inf, cálculo de Macro F1, checkpoint, reload, resume e geração de predições. Registre uso de GPU e pico de memória quando disponível.

Gerações

Organize os experimentos cumulativos:

G0 Smoke: pipeline mínimo, um fold, uma janela, poucas épocas.

G1 Qualificação: R0, regras e classificadores clássicos achatados.

G2 Temporal: LSTM, TCN e Transformer em R0 para 30, 60 e 150 frames.

G3 Missingness: interpolação e comparação R0/R1/R2.

G4 Imbalance: distribuição original, class weights, weighted sampling e augmentation leve.

G5 Final: melhor configuração, todos os folds e seeds, ablação e estudos de caso.

G6 Fusion: opcional e somente após G5.

Crie arquivos de configuração de geração que listem as execuções planejadas. Faça dry-run que expanda a matriz e estime quantidade de runs antes de executá-la. Permita filtrar modelo, fold, seed e janela. Não use resultados do teste de uma geração para criar silenciosamente a próxima; registre mudanças exploratórias em docs/decisions.

Busca de hiperparâmetros

Não execute grid search cartesiano gigante. Implemente busca limitada em duas etapas. Na triagem, use uma seed, treino/validação interna e pequeno espaço predefinido. Na confirmação, execute as configurações selecionadas nos quatro folds e em pelo menos três seeds.

XGBoost, LSTM e TCN podem receber maior orçamento. SVM, Random Forest e Transformer precisam de comparação justa, mas com espaço reduzido. Use `val_macro_f1` como objetivo. Em empate, considere recall de Fatigue, falsos alertas por hora e menor complexidade. Nunca selecione por acurácia global.

Salve todos os trials, inclusive falhas, e o motivo. O espaço de busca e o orçamento devem estar em configuração versionável. Não consulte o vídeo externo durante a seleção.

Desbalanceamento e augmentation

Implemente quatro cenários separados: distribuição original; class weights; weighted sampling; augmentation leve. Não combine class weights e weighted sampling no experimento principal sem uma hipótese explícita.

Sampling e augmentation são exclusivos do treino. Validação e teste mantêm a distribuição real. Para séries temporais, implemente jitter pequeno, variação de escala limitada e masking curto. Preserve faixas físicas, coerência temporal e correlações entre indicadores. Não altere flags como se fossem sinais contínuos. Registre parâmetros e seed das transformações.

Compare Macro F1, recall/F1 de Fatigue e Distraction, e falsos alertas por hora. Se augmentation aumentar Macro F1 mas degradar comportamento operacional, documente o trade-off e não o declare automaticamente superior.

Métricas e avaliação

Implemente Macro F1 como métrica principal; precision, recall e F1 por classe; balanced accuracy; matriz de confusão; AUC-ROC one-vs-rest quando matematicamente válida; falsos alertas por hora/sessão; latência de detecção quando mensurável; tempo de treino/inferência; parâmetros e tamanho.

Produza métricas por run e um agregador por modelo, janela, fold e seed, com média, desvio-padrão e intervalos de confiança apropriados. Avalie também eventos completos e sessões. Não trate janelas sobrepostas como observações independentes para inferência estatística.

Se implementar McNemar, documente a unidade de análise e use predições pareadas compatíveis; não aplique ingenuamente a milhares de janelas sobrepostas. Implemente bootstrap em blocos temporais ou eventos como complemento e declare a limitação de quatro vídeos.

Salve predições com identificadores, verdade, classe prevista e probabilidades, sem expor dados pessoais.

Explicabilidade

Para XGBoost, gere importância interna e SHAP quando a dependência estiver disponível. Implemente permutation importance por feature e grupo. Para modelos temporais, priorize ablação por grupos e permutation importance temporal de forma controlada.

Os grupos são: ocular=EAR; oral=MAR; head_pose=Pitch/Yaw/Roll; missingness=flags. A ablação oficial deve retreinar o modelo sem o grupo; não apenas zerar a feature no teste.

Crie estudos de caso rastreáveis: verdadeiro positivo de Fatigue, verdadeiro positivo de Distraction, falso positivo, falso negativo e janela com alto missing rate. Gere gráficos de série temporal com verdade, probabilidades e indicadores, sem mostrar frames identificáveis salvo autorização explícita.

Fusão opcional

Somente após G5 estar concluída, implemente late fusion opcional com probabilidades do modelo facial, evidência de celular e sinais corporais. O meta-classificador deve ser treinado com probabilidades out-of-fold dos modelos-base. Nunca use previsões in-sample dos mesmos exemplos usados para treinar a base.

Compare a fusão com o melhor modelo facial isolado e mantenha OperatorAbsent como estado operacional separado até haver validação suficiente para alterar a taxonomia. Se faltarem previsões alinhadas dos módulos anteriores, documente o contrato de entrada e não invente dados.

Relatórios e gráficos

Crie comandos reproduzíveis para gerar: distribuição de classes por frame e janela; missingness por vídeo/classe; duração de gaps; curvas de treino; comparação de janelas; comparação de modelos; matriz de confusão normalizada e absoluta; métricas por fold/seed; efeitos de balanceamento; ablação; importância; tempo/memória; e estudos de caso.

Gráficos devem ter título, eixos, unidades, legenda, paleta consistente e versão vetorial ou alta resolução adequada à dissertação. Gere tabelas em CSV e, quando útil, LaTeX. Não dependa de copiar valores manualmente de notebooks.

Testes obrigatórios

Crie testes para schema e validação do dataset; regras de rótulo das janelas; Transition/Mixed; construção das três janelas; splits leave-one-video-out; blocos contínuos; purge gap; ausência de interseção; fit de preprocessing apenas no treino; interpolação curta; flags; MissingDurationSoFar causal; métricas; ordem das classes; checkpoint save/load/resume; determinismo básico; e uma execução end-to-end em dados sintéticos pequenos.

Dados sintéticos são permitidos apenas em testes e devem estar claramente identificados. Eles nunca podem aparecer como resultado científico. Execute lint/format/test conforme as ferramentas já adotadas pelo projeto.

README e documentação

Atualize README.md com objetivo científico, escopo, estrutura, instalação, preparação dos dados, comandos de validação, geração de janelas, treino, resume, avaliação, agregação, gráficos e reprodução das gerações. Inclua exemplos seguros que não exponham caminhos reais.

Mantenha docs/methodology com decisões metodológicas, docs/decisions com ADRs curtos e docs/current_state.md com estado factual. Documente claramente a diferença entre R0 N×5, R2 N×8, janela achatada e features agregadas. Explique que os thresholds pertencem ao baseline, enquanto os outros modelos aprendem fronteiras.

Sequência de execução e checkpoints

Execute nesta ordem:

1. Inspeção e inventário.
2. Scaffold mínimo, configurações e dependências.
3. Schema, validações e manifesto.
4. Janelas, diagnósticos e testes.
5. Splits e testes contra vazamento.
6. Preprocessamento R0-R3 e testes.
7. Métricas e baselines clássicos.
8. Training engine, GPU, early stopping e checkpoints.
9. LSTM, TCN e Transformer.
10. G0 smoke test.
11. Dry-run da matriz experimental e estimativa de custo.
12. G1/G2; depois G3/G4; finalmente G5.
13. Explicabilidade, relatórios e apenas então G6 opcional.

Ao fim de cada etapa, execute os testes relevantes, registre o que foi criado, comandos usados, resultados observados e próximo passo. Faça commits lógicos somente se isso estiver autorizado no ambiente; não envie para remoto sem pedido explícito.

CrITÉRIOS de parada e comunicação

Pare e informe o bloqueio quando: dados necessários não existirem; o formato real contradizer o schema sem regra clara; houver ambiguidade de rótulo que altere o target; for necessário acessar credenciais ou serviços não configurados; houver risco de expor dados da empresa; ou a GPU exigir alteração destrutiva do ambiente.

Quando um treinamento falhar, preserve logs e checkpoints, diagnostique causa provável e proponha ação segura. Não repita indefinidamente a mesma execução. Se os resultados forem ruins, primeiro audite rótulos, distribuição, missingness, leakage, baseline trivial e curvas de aprendizado. A classificação binária Alert vs Non-Alert é contingência científica e só deve ser implementada como experimento separado e documentado, nunca como substituição silenciosa da taxonomia principal.

Definição de pronto

Considere a implementação central pronta quando o pipeline puder, por comandos reproduzíveis: validar o dataset; gerar janelas e distribuições; criar os quatro folds sem vazamento; treinar e retomar modelos com GPU/CPU; executar regras, SVM, RF, XGBoost, LSTM, TCN e Transformer; comparar 30/60/150 frames; registrar configurações/checkpoints/predições; agregar folds e seeds; gerar métricas, tabelas e figuras; executar ablações; e documentar limitações.

Na sua primeira resposta, não comece treinamentos longos. Apresente o inventário inicial de fase_2, os riscos encontrados, o plano de arquivos e os primeiros quality gates. Em seguida, implemente autonomamente as etapas seguras e verificáveis. Priorize correção científica, prevenção de vazamento e rastreabilidade sobre quantidade de modelos executados.

Base documental

- LOPES, Eduardo Lamy. Documento de Qualificação — Fatigue and Distraction Detection for Heavy Machinery Teleoperation. PUCPR, 2026.
- LOPES, Eduardo Lamy. Plano Pós-Banca. PUCPR, 2026.
- LOPES, Eduardo Lamy. Plano de Ações Pós-Banca — versão atualizada. PUCPR, 2026.

Este plano integrado consolida os documentos anteriores e passa a ser a referência operacional para a implementação da fase_2.