

Plano de Ações Pós-Banca

Eduardo Lamy Lopes

Sumário

1. Data augmentation e impacto do desbalanceamento	2
2. Estrutura hierárquica e fusão das abordagens.....	3
3. Pré-processamento, interpolação e flags de falha	4
4. Explicabilidade.....	5
4.1 Feature Importance Global - saber quais indicadores foram mais relevantes?	5
4.2 Ablation Study - Treinar/remover grupos e medir queda de desempenho	6
4.3 Estudos de casos	6
PRÓXIMOS MESES – Organização daqui pra frente.....	7
Mês 1 — Organização dos dados e diagnóstico	7
Mês 2 — Pré-processamento e features	8
Mês 3 — Modelos principais (já estava no doc como H3)	8
Mês 4 — Desbalanceamento e augmentation.....	8
Mês 5 — Fusão e explicabilidade	8
Mês 6 — Juntar tudo e escrita do doc final.....	8
Sobre resolver por visão computacional diretamente	9
Anotações minhas vendo o vídeo da apresentação:.....	10

1. Data augmentation e impacto do desbalanceamento

O professor sugeriu medir melhor quanto o desbalanceamento afeta o modelo e testar se data augmentation ajuda ou prejudica a generalização. Isso é muito pertinente porque fadiga tende a ser uma classe rara em vídeos operacionais reais. O próprio documento já reconhece esse problema e propõe Macro F1-score, weighted cross-entropy e weighted sampling como formas de reduzir viés para a classe majoritária

O que pode ser feito:

Fazer uma análise comparando:

1. Cenários que estão sem balanceamento (modelo treinado diretamente com a distribuição real dos dados)
2. Class weights / weighted loss - Penalizando mais erros nas classes mais raras, principalmente fadiga.
3. Weighted sampling - Aumentar a frequência de janelas de fadiga no treinamento.
4. Data augmentation nas séries temporais - Augmentation nos 5 indicadores

A ideia continua sendo trabalhar em cima dos dados reais da empresa. O data augmentation não substitui dados reais que a empresa mandou, mas será tratado como uma técnica experimental para avaliar se pequenas variações geradas a partir dos próprios dados da TELEOP ajudam o modelo a generalizar melhor ou se introduzem artefatos.

"Ablation study": sem balanceamento vs weighted loss vs weighted sampling vs augmentation leve.

2. Estrutura hierárquica e fusão das abordagens

O professor percebeu que o trabalho tem vários tipos de informação: indicadores corporais, uso de celular, indicadores faciais e séries temporais. A sugestão dele é deixar mais claro como essas características extraídas do operador podem ser trabalhadas em conjunto.

O que pode ser feito:

Da para criar uma subseção Hierarchical Fusion Strategy ou Fusion of Operator Monitoring Evidence

mostrando que existem 3 grupos de evidencias:

- corpo(postura;maos fora do controle;presença)
- uso de celular
- face (5 indicadores e evolução temporal desses indicadores).

O modelo facial temporal gera probabilidades dos estados, o detector de celular gera probabilidade de distração, o corporar gera sinais de contexto. Isso tudo para um meta-classificador simples (Regressão/RandomForest/XGBoost) decidindo o estado final entre Alerta;Fadiga;Distracao;Operador ausente.

Seria um misto do que ja foi feito nos artigos antigos com a proposta da fase 3.

O importante seria explicar a arquitetura de fusão como proposta conceitual e implementar uma versão simples de late fusion, caso dê tempo. Seria um experimento complementar ou extensão da arquitetura - o foco ainda é o H3 que foi colocado, esse seria um adicional legal para colocar nos trabalhos futuros

3. Pré-processamento, interpolação e flags de falha

Hoje, quando o MediaPipe não detecta o rosto, você zera os indicadores. Isso preserva a série temporal, mas pode confundir o modelo: ele pode aprender que zero é um valor real de EAR/MAR/pitch, quando na verdade é ausência ou falha de detecção.

No documento, já é reconhecido que a taxa de detecção do MediaPipe Face Mesh variou bastante, entre 42% e 83,7%, e que os frames sem detecção foram mantidos como vetores zerados.

O que pode ser feito:

Criar um pipeline de pré-processamento com três situações:

1. Detecção válida - usa normal os 5 indicadores
2. Falha curta - Exemplo: Se gap ≤ 15 ou 30 frames: interpolação linear ou outro metodo (forward fill/backward fill/rolling median)
3. Falha longa - Exemplo do operador ausente. Não interpolar como se fosse dado real, manter valor zerado ou mediana + marcar flag de ausência e talvez classificar como operador ausente se for longo

hoje a matriz de entrada é Nx5 mas pode ser Nx8:

5 indicadores + 3 flags:

face_detected; was_interpolated; missing_duration

Pelo menos implementar a interpolação curta + flags de validade/interpolação seria legal para o trabalho, tem muitas comparações que da para fazer e features derivadas possíveis para explorar (media móvel, porcentagens de frames sem detecção, variação de cada indicador, variância na janela, proporção do indicador abaixo do limiar, etc).

4. Explicabilidade

O professor comentou que da para fazer o modelo não ser apenas uma caixa-preta. os indicadores já são interpretáveis pois os indicadores na verdade têm significado físico. O baseline de regras já mostra o problema de thresholds fixos e indicadores isolados, enquanto a arquitetura temporal tenta aprender correlações e progressão temporal. foi comentado do SHAP, que é uma técnica de explicabilidade baseada em valores de Shapley, da teoria dos jogos, usada para estimar a contribuição de cada variável na predição do modelo.

O que pode ser feito:

Da para quebrar em alguns experimentos (3 no total)

1. Saber quais indicadores são mais relevantes
2. Treinar/remover grupos e medir queda de desempenho
3. Escolher casos diferentes e mostrar os principais indicadores responsáveis na classificação

4.1 Feature Importance Global - saber quais indicadores foram mais relevantes?

Talvez criar uma seção no doc com titulo Model Interpretability and Feature Contribution Analysis. Da para quebrar em 4 experimentos menores:

- 1) usar SHAP para Random Forest/XGBoost; (não sei como que fica em modelos temporais, teria que testar mas o ideal seria nesses classificadores classicos mesmo)
- 2) fazer permutation importance (talvez o mais viavel por questao de tempo)
- 3) ganho/importância do XGBoost;
- 4) Ablação por grupo de indicadores. (talvez o mais viavel por questao de tempo)
 - Grupo ocular: EAR
 - Grupo oral: MAR
 - Grupo head-pose: pitch, yaw, roll
 - Grupo missingness: flags de detecção/interpolação
 - Grupo objeto/corpo: phone, hands, posture, absence

4.2 Ablation Study - Treinar/remover grupos e medir queda de desempenho

- Todos os indicadores;
- Sem EAR;
- Sem MAR;
- Sem Head Pose;
- Apenas EAR/MAR;
- Apenas Head Pose;
- Com e sem flags de missing/interpolation.

Se tirar EAR e a classe Fatigue piorar muito, mostra que EAR é relevante para fadiga.

Se tirar pitch/yaw/roll e Distraction piorar, mostra que pose da cabeça contribui para distração e assim por diante.

4.3 Estudos de casos

Escolher alguns trechos reais e mostrar:

Entrada temporal -> predição -> principais indicadores responsáveis

- Caso de fadiga provável; Caso de distração; 1 Falso positivo; 1 Falso negativo.

ai daria para falar algo como "Neste caso, a predição de fadiga foi influenciada principalmente pela queda progressiva do EAR, aumento do MAR e alteração de pitch dentro da janela" que era o slide da evolução dos indicadores ao longo do tempo

- usar SHAP nos modelos clássicos, especialmente XGBoost/Random Forest;
- usar ablação e permutation importance para LSTM/TCN e classificadores temporais;
- usar exemplos visuais/cases para explicar as decisões.

PRÓXIMOS MESES – Organização daqui pra frente

Mês 1 — Organização dos dados e diagnóstico

- Fechar dataset anotado.
Anotações manuais que serão usadas nos experimentos. Isso inclui revisar se todos os trechos estão corretamente marcados como alerta, fadiga, distração ou ausência/falha de detecção, garantindo que o conjunto de dados esteja pronto para ser usado no treinamento e na avaliação dos modelos – Revisar pois já fiz isso mas verifiquei que muitos trabalhos comentam de ter mais de 1 anotador para não ter viés
- Gerar distribuição por classe: frame-level e window-level.
Analisar quantos exemplos existem de cada classe. Primeiro, essa contagem será feita frame a frame, ou seja, verificando quantos frames foram anotados como alerta, fadiga ou distração (Até aqui já foi feito). Fazer a mesma análise pelas janelas temporais (30/60/150 frames), que são pequenos blocos de frames consecutivos usados como entrada dos modelos.
Ex: Janela de 30 frames n.1: 25 Fadigue; 5 Alert -> Classe da janela: Fadigue.
E assim por diante, usando blocos de tamanhos diferentes ao longo dos 4 vídeos.
- Medir missing rate por vídeo, por janela e por classe.
Verificar com que frequência não dá para detectar corretamente o rosto ou os pontos faciais. Essa análise é feita separadamente para cada vídeo, para cada janela temporal e para cada classe. O objetivo é entender se as falhas de detecção acontecem mais em determinados vídeos (como o vídeo 4 que o operador saiu por uns 4 minutos), em certos estados do operador ou em situações específicas, como oclusão, iluminação ruim ou operador ausente.
- Definir splits sem vazamento temporal.
Planejar como os dados serão divididos para treinar e avaliar os modelos. Como os vídeos serão transformados em janelas temporais, não é adequado separar as janelas de forma aleatória, porque janelas muito próximas podem ser muito parecidas. Isso poderia fazer com que o modelo visse no treino informações quase iguais às usadas no teste, gerando resultados artificialmente melhores. Portanto, a divisão precisa respeitar a ordem temporal dos vídeos.
- Avaliar qual será a melhor forma de testar a capacidade de generalização do modelo.
Uma possibilidade é testar o modelo em uma sessão/vídeo inteiro que ele não viu durante o treinamento. Por exemplo, treinar com três vídeos e testar no quarto. Outra possibilidade é dividir cada vídeo em blocos grandes e contínuos, como usar os primeiros minutos para treino, uma parte intermediária para validação e os minutos finais para teste. O importante é evitar que janelas temporais muito próximas fiquem misturadas entre treino e teste.

Mês 2 — Pré-processamento e features

- Zero-fill como baseline - Que é o tratamento que já tem hoje de deixar o indicador como 0, mas teria que deixar isso como baseline no documento.
- Implementar interpolação para gaps curtos.
Quando a falha de detecção ocorrer por poucos frames consecutivos, será testada a interpolação dos valores ausentes. A ideia é estimar esses valores com base nos frames anteriores e posteriores válidos, evitando que pequenas falhas interrompam a continuidade da série temporal. Por exemplo, se o MediaPipe falhar por 10 ou 15 frames, mas detectar normalmente antes e depois, os valores podem ser aproximados por interpolação linear, preenchimento pelo último valor válido ou média móvel.
- Implementar flags de validade/interpolação.
flag indicando se aquele valor foi realmente detectado, se foi interpolado ou se representa ausência/falha de detecção. O modelo não recebe apenas os indicadores, mas também sabe a origem daquele dado. Isso evita que ele trate valores estimados ou ausentes como se fossem medições reais. Vai mudar o tamanho da matriz de entrada do modelo para ter as flags além dos indicadores.
- Adicionar features derivadas simples: deltas, média, variância, missing ratio.

Mês 3 — Modelos principais (já estava no doc como H3)

- Treinar classificadores clássicos: SVM, Random Forest, XGBoost.
- Treinar LSTM e TCN.
- Testar Transformer como comparação, sem depender dele como resultado principal.
- Avaliar diferentes janelas: curta, média e longa.

Mês 4 — Desbalanceamento e augmentation

- Comparar sem balanceamento, class weights e weighted sampling.
- Testar augmentation leve nas séries temporais.
- Verificar se augmentation melhora Macro F1 ou apenas aumenta falso positivo.
- Documentar se ajuda ou prejudica.

Mês 5 — Fusão e explicabilidade

- Implementar fusão simples se der tempo.
- Fazer ablation study por grupo de indicadores.
- Gerar SHAP/feature importance para modelos clássicos.
- Fazer estudos de caso com trechos reais.

Mês 6 — Juntar tudo e escrita do doc final

- Análise estatística.
- Organização dos resultados.
- Discussão das limitações.
- Escrita final.
- Preparação da defesa.

Sobre resolver por visão computacional diretamente

(pergunta que é feita em todas as apresentações e o que mais gera confusão para quem é da parte de tecnologia e vê a apresentação a 1ª vez – Essa parte tem que ficar muito clara):

Sim, daria para tentar resolver direto com vídeo bruto usando CNN ou VideoTransformer, ou até VLM. Mas isso não necessariamente é melhor para o cenário.

O caminho que foi feito tem uma vantagem forte que é usar visão computacional para extrair sinais interpretáveis (com o mediapipe/opencv, que já funciona muito bem hoje e é leve – graças ao trabalho do Google) e depois usar aprendizado temporal (machine learning) para modelar a evolução desses sinais.

Usar uma abordagem diretamente sobre vídeo bruto é possível, mas exigiria mais dados anotados, mais custo computacional e teria maior risco de overfitting ao cenário específico da cabine (dificuldades que mostrei como iluminação, posição da câmera).

Neste trabalho, a escolha por indicadores temporais tem 3 pontos bem positivos:

- 1) reduz a complexidade,
- 2) melhora a interpretabilidade
- 3) permite comparar de forma controlada as regras fixas, os classificadores clássicos e as arquiteturas temporais sobre a mesma entrada/dados

Anotações minhas vendo o vídeo da apresentação:

Aqui eu fui escrevendo conforme assisti o vídeo da apresentação, então dá para pular essa parte, deixei apenas como anotações/referência das palavras do prof. Danilo...

Professor da banca comentou de usar data augmentation. E de verificar quanto que o desbalanceamento tá afetando, se com data augmentation ajuda ou piora para ele generalizar melhor

- eu comentei que a intenção do projeto é resolver o problema da empresa e trabalhar em cima dos dados da empresa. (talvez não ficou tão claro o que eu quis dizer aqui- era para comentar mais sobre não ser um problema ficar super específico para um operador ou ter uma generalização tão ruim, se funcionar para a empresa e o operador principal está bom).

teve 3 pontos principais que o professor Danilo comentou que ajudam na metodologia:

(1) Criar a estrutura mais hierárquica com fusão das abordagens/indicadores e explicar melhor como que todas as características extraídas do operador serão trabalhadas em conjunto.

talvez fazer um módulo com 3 saídas probabilísticas de estados (alerta/fadiga/distração) e depois fazer uma meta classificação - sempre olhando os 3 grupos juntos (linha da taxonomia hierárquica - até da para fazer quais classificadores contribuem melhor para cada nível)

(2) escopo/pré-processamento - Interpolação na série temporal caso tenha problema de detecção. Talvez extrair mais características e colocar um conjunto agregado - em alguns casos o pessoal coloca flags no final se o valor que foi colocado foi por interpolação, ampliando o vetor de características e informando o tipo de tratamento que foi feito no dado. Pois desse modo quando passa para o classificador, ele consegue entender para aquelas amostras o ajuste adequado dos pesos que ele deu, para ele simplesmente não cair em uma generalização e falar "não tem coleta desse indicador", então vai fazendo aproximações pois vai injetando dados que são mais aceitáveis, e pelo grande volume que vai ter devido ao tempo das leituras, isso pode acabar ajudando bastante. Se for intervalo curto - interpolação, se for intervalo longo - substitui.

(3) Verificar/Rever Explicabilidade - explicar o motivo se causou fadiga ou causou distração por exemplo. Quais indicadores que de fato apontam isso. Da para fazer de várias formas. da para fazer de várias formas, da para pegar pela feature importance, ali pelo SHEP/SHAP(?). Ou da para agrupar por classes e fazer o reverso e tentar trazer qual que é o principal indicador que está ocorrendo ou fazer a ideia da exclusão, tirando alguns indicadores para entender quem que tem a principal importância dentro do contexto. Mostrar alguns casos/testagens com base na interpretação de estudo da feature e achar quem é o indicador com maior relevância/score ali. Explicabilidade - como chegou no target e quais as variáveis. Tem várias bibliotecas legais como o shep para mostrar e ver a parte do score com o que tá olhando, pela teoria de jogos do cálculo tá bantendo com o que está sendo feito experimentalmente e se eu fui fazendo por exclusão de algumas features para ver exatamente se ela tem um fator forte da relação dela com a classe alvo.